



专注于商业智能BI和大数据的垂直社区平台

一元线性回归的参数估计

Allen

www.hellobi.com


课程目录

- 最小二乘法
- 回归参数的最小二乘估计
- 最小二乘估计量的性质
- 小结

最小二乘法

- 一元线性回归模型可表示为: $y = \beta_0 + \beta_1 x + \varepsilon$
- 一元线性回归中估计的回归方程为: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

如果不加限制，通过样本点，可以求出多个回归方程



怎么选取估计的回归方程呢？


最小二乘法

- 现假设已知一元线性回归中估计的回归方程为: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$
- 若有一个样本点 (x_i, y_i) , 样本点带入估计的回归方程中求得的估计值为 \hat{y}_i
- 很自然的想法就是使估计值 \hat{y}_i 与真实观测值 y_i 的差 $e_i = y_i - \hat{y}_i$ 尽量小, 把 $e_i = y_i - \hat{y}_i$ 称为**残差**, 最小二乘法就是选择一条直线使得残差平方和最小



最小二乘法

- 想要使残差和最小，即 $\min(\sum e_i)$ 或者 $\min(\sum |e_i|)$ 或者 $\min(\sum e_i^2)$ ，如图



即观测值和和回归值
在y轴的距离和最短

最小二乘法

- 要使残差平方和可表示为 $Q(\hat{\beta}_0, \hat{\beta}_1) = \sum e_i^2 = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$
- 要使上式达到最小，根据求极值原理可得如下方程组：

$$\begin{cases} \frac{\partial Q(\hat{\beta}_0, \hat{\beta}_1)}{\partial \hat{\beta}_0} = \frac{\partial \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{\partial \hat{\beta}_0} = 0 \\ \frac{\partial Q(\hat{\beta}_0, \hat{\beta}_1)}{\partial \hat{\beta}_1} = \frac{\partial \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{\partial \hat{\beta}_1} = 0 \end{cases}$$

最小二乘法

- 将以上方程组整理得：
$$\begin{cases} \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0 \end{cases}$$
- 解以上方程组得：
$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \end{cases}$$
- 通常称 $\hat{\beta}_0$ 和 $\hat{\beta}_1$ 为 β_0 和 β_1 的**最小二乘估计**

最小二乘估计量的性质——期望

- 1.求 $\hat{\beta}_0$ 和 $\hat{\beta}_1$ 的均值：
$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \end{cases}$$
- 首先将 $\hat{\beta}_1$ 化简得：
$$\hat{\beta}_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} - \frac{\sum (x_i - \bar{x}) \bar{y}}{\sum (x_i - \bar{x})^2}$$
- 由于：
$$\sum (x_i - \bar{x}) = \sum x_i - \sum \bar{x} = n\bar{x} - n\bar{x} = 0$$
- 化简：
$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})(\beta_0 + \beta_1 x_i + \varepsilon_i)}{\sum (x_i - \bar{x})^2} = \frac{\beta_1 \sum (x_i - \bar{x}) x_i + \sum (x_i - \bar{x}) \varepsilon_i}{\sum (x_i - \bar{x})^2}$$

最小二乘估计量的性质——期望

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum (x_i - \bar{x})y_i}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})(\beta_0 + \beta_1 x_i + \varepsilon_i)}{\sum (x_i - \bar{x})^2} = \frac{\beta_1 \sum (x_i - \bar{x})x_i + \sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2} \\&= \frac{\beta_1 \sum (x_i - \bar{x})x_i - \beta_1 \sum (x_i - \bar{x})\bar{x} + \beta_1 \sum (x_i - \bar{x})\bar{x} + \sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2} = \frac{\beta_1 \sum (x_i - \bar{x})^2 + \beta_1 \sum (x_i - \bar{x})\bar{x} + \sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2} \\&= \beta_1 + \frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2}\end{aligned}$$

• 两边去期望值： $E(\hat{\beta}_1) = \beta_1 + \frac{\sum (x_i - \bar{x})E(\varepsilon_i)}{\sum (x_i - \bar{x})^2} = \beta_1$

表明 $\hat{\beta}_1$ 是 β_1 的无偏估计量

最小二乘估计量的性质——期望

• 由于： $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

• 所以： $E(\hat{\beta}_0) = E(\bar{y} - \hat{\beta}_1 \bar{x}) \longrightarrow = E(\beta_0 + \beta_1 \bar{x} + \bar{\varepsilon} - \hat{\beta}_1 \bar{x}) \longrightarrow = \beta_0 + \beta_1 \bar{x} + E(\bar{\varepsilon}) - \bar{x}E(\hat{\beta}_1)$

$$= \beta_0 + \beta_1 \bar{x} + 0 - \bar{x}\beta_1 \longrightarrow = \beta_0$$

表明 $\hat{\beta}_0$ 是 β_0 的无偏估计量

最小二乘估计量的性质——方差

- $\hat{\beta}_1$ 的方差： $D(\hat{\beta}_1) = E(\hat{\beta}_1 - E(\hat{\beta}_1))^2 = E(\hat{\beta}_1 - \beta_1)^2$
- 因为： $\hat{\beta}_1 = \beta_1 + \frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2}$ 即： $\hat{\beta}_1 - \beta_1 = \frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2}$
- 所以：
$$\begin{aligned} (\hat{\beta}_1 - \beta_1)^2 &= \left(\frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2} \right)^2 = \frac{((x_1 - \bar{x})\varepsilon_1 + \cdots + (x_n - \bar{x})\varepsilon_n)^2}{\left(\sum (x_i - \bar{x})^2 \right)^2} \\ &= \frac{\left(\sum (x_i - \bar{x})^2 \varepsilon_i^2 + \sum_{i \neq j} (x_i - \bar{x})(x_j - \bar{x})\varepsilon_i \varepsilon_j \right)}{\left(\sum (x_i - \bar{x})^2 \right)^2} \end{aligned}$$

最小二乘估计量的性质——方差

- 两边取期望值：
$$E(\hat{\beta}_1 - \beta_1)^2 = \frac{\left(\sum (x_i - \bar{x})^2 E(\varepsilon_i^2) + \sum_{i \neq j} (x_i - \bar{x})(x_j - \bar{x}) E(\varepsilon_i \varepsilon_j) \right)}{\left(\sum (x_i - \bar{x})^2 \right)^2}$$
- 由假设可知： $E(\varepsilon_i^2) = \sigma^2$ $E(\varepsilon_i \varepsilon_j) = 0$
- 所以：
$$E(\hat{\beta}_1 - \beta_1)^2 = \frac{\sum (x_i - \bar{x})^2 \sigma^2}{\left(\sum (x_i - \bar{x})^2 \right)^2} = \frac{\sigma^2}{\sum (x_i - \bar{x})^2} \quad \text{即} : D(\hat{\beta}_1) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$
- 同理：
$$D(\hat{\beta}_0) = \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}$$

小结

- 最小二乘法
- 回归参数的最小二乘估计
- 最小二乘估计量的性质
- 小结